Cheatsheet: Test-Time Scaling（2019 → 2026）

Parallel · Sequential · Search · Latent · Test-Time Training —how models spend compute at inference

Yiwen 整理·90+ 篇论文与官方发布·数字均出自原文（arXiv / 官方博客）·2026 年 10 月核对

核心问题：模型训练完以后，**推理时多花算力**能不能换来更好的答案？花在哪里最划算？
怎么读：每节 问题 → 方法（算法 / 公式） → **数字** → 局限。**记号：**x 题目，y 解答，π 生成模型，V 验证器，N 采样数，C 推理算力预算。

统一形式化：用推理算力换准确率

Best-of-N $y_i \sim \pi(\cdot|x),\ i=1..N,\quad \hat{y}=\arg\max_{y_i} V(x,y_i)$
多数投票 $\hat{a}=\arg\max_a \sum_i \mathbf{1}[\text{ans}(y_i)=a]$
加权投票 $\hat{a}=\arg\max_a \sum_i V(x,y_i)\,\mathbf{1}[\text{ans}(y_i)=a]$
覆盖率 pass@k（无偏估计，n 个样本中 c 个对）：
$\text{pass@}k = 1-\binom{n-c}{k}/\binom{n}{k}$
算力账（Snell 等）：$X = \underbrace{6ND_{\text{pre}}}_{\text{预训练}} + \underbrace{2ND_{\text{inf}}}_{\text{推理}}$，$N$ 参数量，D token 数
Compute-optimal：$\theta^*(x,C)=\arg\max_\theta \mathbb{E}_{y\sim\text{Target}(\theta,C,x)}[\mathbf{1}[y=y^*]]$，按题目难度选策略 θ
关键区分：覆盖率需要**知道答案对不对**（oracle）；实际准确率受**挑选方法**（投票 / 验证器）限制。

五种花推理算力的方式

方式	怎么花	代表	需要 / 局限
并行	独立采 N 个再聚合	Best-of-N、自一致性、Deep Think	聚合器；投票会饱和
串行	一条写更长 / 反复修改	CoT、Self-Refine、o1 / R1、s1	会自我纠错；想太多 / 太少
搜索	在中间步骤上展开、打分、剪枝	ToT、PRM beam search、MCTS	步骤级验证器；调用多
潜空间	循环更多层，不多写 token	Coconut、Recurrent Depth	专门架构；不可读
更新参数	在测试样本上训练	TTT、TTT-ARC、TTRL、TTT-Discover	自监督 / 伪标签；每题一次训练

主线：阶段 1–6 是**外挂**在模型外的算法 → 阶段 7 起被 **RL 训练进模型** → 2025 年后变成 **API 旋钮**（预算 / 强度 / 自适应）和**并行思考**顶配档。

0. 前史：搜索可以替代训练（2021）

Scaling Scaling Laws with Board Games Andy L. Jones ·2104.03113 ·2021-04

AlphaZero 下 Hex，同时改变训练算力和推理时 MCTS 算力：

关键结论

"训练算力每多 10×，大约可以省掉 15× 的推理算力"——两者在一条等性能线上可以互换（直到只剩单节点搜索）。

语言模型缺两样东西：可以展开的搜索树，和可靠的打分函数。后面十年都在补这两样。

1. 多采几个，再挑一个（2021–2022）

Training Verifiers (GSM8K) OpenAI ·2110.14168 ·2021-10

- GSM8K：8.5K 小学数学题（7.5K 训练 / 1K 测试）。
- **验证器训练**：用生成器采的解，按最终答案对错打标签，训练模型预测"这个解对不对"（逐 token 预测价值）。
- 推理：每题采 **100** 个解，取验证器分数最高的。
- **6B + 验证器略胜微调的 175B**，相当于模型放大约 **30**×。
- 采样数太大时效果反而下降：验证器会被"骗过"。

AlphaCode DeepMind ·2203.07814 ·2022-02

```
每题采样 ~ 百万个程序
  → 用题目样例测试过滤（去掉约 99%）
  → 在生成的测试输入上按输出行为聚类
  → 每个大类挑一个，最多提交 10 个
```

Codeforces（5,000+ 人比赛）前 **54.3%**，估计等级分 1238。

局限

需要单独训练验证器（或有可执行测试）；采样量大；验证器分数会被过度优化。

2. 让模型多写几步：思维链（2022）

Chain-of-Thought Prompting Google ·2201.11903 ·2022-01

- 少样本示例里写出推理过程。PaLM 540B GSM8K：17.9% → **56.9%**（超过当时微调 GPT-3 + 验证器的 55%）。
- 只有足够大的模型才受益（"涌现"）。

Zero-shot CoT 东京大学·2205.11916 ·2022-05

```
Q: ... A: Let's think step by step.
  → [推理]
Therefore, the answer (arabic numerals) is
  → [答案]
```

MultiArith 17.7 → 78.7, GSM8K 10.4 → 40.7 (text-davinci-002)。

要点：*CoT* 让每道题的计算量可变——难题可以写更多 *token*，这就是"串行" *scaling* 的起点。

3. 自一致性：多条推理投票（2022–2024）

Self-Consistency Google ·2203.11171 ·2022-03

```
for i in 1..N:   # 论文 N = 40，温度采样
    r_i, a_i ← sample CoT(x)
return majority_vote(a_1..a_N)  # 只看最终答案
```

相对 CoT 贪心解码	提升
GSM8K / SVAMP / AQuA	+17.9 / +11.0 / +12.2
StrategyQA / ARC-c	+6.4 / +3.9
code-davinci-002 GSM8K	60.1 → 78.0
PaLM-540B GSM8K	56.5 → 74.4

直觉：错误的推理五花八门，正确的推理殊途同归。

Universal Self-Consistency Google ·2311.17311 ·2023-11

开放式输出无法精确比对 → 把所有候选拼进提示，让模型选"最一致"的。PaLM 2-L GSM8K：贪心 85.7 / SC 90.4 / USC 90.2。

Are More LLM Calls All You Need? Stanford ·2403.02419 ·2024-03

投票准确率随调用次数可能**先升后降**：简单题越投越对，难题上错误答案占多数时越投越错。可以拟合出最优调用数 K^*。

局限

只看最终答案；需要答案可比对；会饱和（数百个样本后几乎不再涨）。

4. 过程奖励：给每一步打分（2022–2024）

问题

答案对，过程可能错；结果奖励（ORM）只看结尾，没法在推理中途指导搜索。

Process vs. Outcome Feedback DeepMind ·2211.14275 ·2022-11

GSM8K：两种监督最终答案错误率相近，但在答案正确的解中，**推理过程错误率 14.0% → 3.4%**（过程监督）。

Let's Verify Step by Step OpenAI ·2305.20050 ·2023-05

- **PRM800K**：人工给每一步标正确 / 错误 / 中性，共 80 万个步骤标签；用主动学习专挑"答案错但看起来很像对的"解来标。
- 整条解的分数 = 各步都正确的概率：$\text{PRM}(y)=\prod_t p(\text{step}_t \text{ 正确})$
- MATH 子集、从 1,860 个解中挑：**PRM 78.2%** vs ORM 72.4% vs 多数投票 69.6%。

Math-Shepherd 北京大学·2312.08935 ·2023-12

自动标步骤：从第 t 步之后续写 N=8 次，

- **Hard**：$y_t=1$ 若任一续写到达正确答案
- **Soft**：y_t = 到达正确答案的续写比例

Mistral-7B(逐步 PPO)：GSM8K 77.9 → 84.1,MATH 28.6 → 33.0；再加验证 89.1 / 43.5。

Rewarding Progress (PAV) CMU / Google ·2410.08146 ·2024-10

一步的价值 = **进步**：$A^\mu(s_t,a_t)=Q^\mu(s_t,a_t)-V^\mu(s_t)$，在另一个"证明者"策略 μ 下估计答对概率的变化。比 ORM 准 8% 以上、算力效率高 1.5–5×；用于在线 RL 时样本效率 5–6×。

	ORM	PRM
打分对象	整条解	每一步
标注	便宜（看答案）	贵（或自动续写估计）
用途	best-of-N 重排	重排 + **搜索剪枝**
风险	对的答案错的过程	被模型钻空子

5. 树搜索与自我修正（2023）

Self-Refine CMU ·2303.17651 ·2023-03

```
y ← M(x)
repeat: fb ← M(x, y, " 给出反馈")
        y  ← M(x, y, fb, " 据此修改")
until 反馈说" 已经很好" 或 达到轮数
```

同一个模型、不训练；7 个任务平均约 +20%（绝对）。

Tree of Thoughts Princeton / Google DeepMind ·2305.10601 ·2023-05

四个组件：(1) 把推理拆成"思维"步 (2) 生成候选（独立采样或一次提出多个）(3) 模型自评状态（打分 / 投票："sure / likely / impossible"）(4) 搜索：BFS（每层留 b 个）或 DFS + 回溯。

24 点游戏（GPT-4）	成功率
CoT	4%
CoT-SC（k=100）	9%
ToT（b=1）	45%
ToT（b=5）	**74%**

RAP UC San Diego ·2305.14992 ·2023-05

同一个 LLM 既是 agent 也是**世界模型**（预测执行动作后的状态），用 **MCTS** 搜索：UCT = $Q(s,a) + w\sqrt{\ln N(s)/N(c(s,a))}$。Blocksworld 上 LLaMA-33B 比 GPT-4 + CoT 相对高 33%；GSM8K 51.6% vs CoT 29.4%。

Graph of Thoughts ETH Zurich ·2308.09687 ·2023-08

思维可以**合并**和**循环**，组成图。排序 128 个数：质量比 ToT 高 62%，成本低 31% 以上。

PRM 引导的搜索（常用形式） 见 Snell 等 2408.03314

Beam search：每步采 M 个下一步，按 PRM 分数保留前 N/M 条继续。**Lookahead**：先往后模拟几步再给当前步打分。

局限

每题调用很多次；模型自评往往不可靠；搜索会放大验证器的错误。

6. 推理算力的 scaling law（2024）

Large Language Monkeys Stanford / Oxford · 2407.21787 ·2024-07

- 覆盖率随采样数在 **4 个数量级**内近似对数线性增长。
- SWE-bench Lite（DeepSeek-Coder-V2）：1 次 15.9% → **250 次 56%**，超过当时单次最好的 43%。
- 但**挑选**是瓶颈：多数投票和奖励模型在几百个样本后就饱和。

Scaling Test-Time Compute Optimally UC Berkeley / Google DeepMind ·2408.03314 ·2024-08

- 两条路：**改提议分布**（训练会逐步修改答案的模型，串行）和**对验证器搜索**（PRM + best-of-N / beam / lookahead）。
- 按基座模型在该题上的 pass@1 把题目分成 5 个**难度**档，每档选最优策略。
- 发现：简单题适合**串行修改**，难题需要串行与并行搭配；beam search 在小预算、难题上更好，大预算时 best-of-N 追上。
- Compute-optimal 比 best-of-N 效率高 **4× 以上**。
- 同等 FLOPs：小模型 + 推理算力能胜过 **14×** 大的模型，但只在小模型本来有一定成功率的题上；**最难的题，加预训练更划算**。

Inference Scaling Laws 清华 / CMU ·2408.00724 ·2024-08

证明（加权）多数投票随样本数**饱和**；REBASE 树搜索（按奖励分配扩展预算）让 Llemma-7B 胜过 Llemma-34B，FLOPs 约少一半。

Generative Verifiers (GenRM) Google DeepMind · 2408.15240 ·2024-08

验证 = 生成：

$$V(x,y) = p_\theta(\text{“Yes”} \mid x, y, \text{“答案对吗?”})$$

GenRM-CoT 先写验证推理，再对 K=32 条验证取平均——**验证本身也能 scaling**。GSM8K best-of-N: 73% → 93.4%。

这一阶段的结论

推理算力能和参数量交换，但**收益依赖题目难度和验证器质量**；挑选比生成更难。

7. 把搜索训练进模型：o1 与 R1（2024–2025）

OpenAI o1 OpenAI ·2024-09 ·官方博客

用大规模强化学习训练长思维链。性能**同时**随两种算力提升：RL 训练算力，以及思考时间。

AIME 2024	准确率
GPT-4o	12%
o1（单次）	74%
o1（64 次投票）	83%
o1（1,000 个样本 + 打分模型重排）	93%

DeepSeek-R1 DeepSeek ·2501.12948 ·2025-01

R1-Zero：基座直接 RL，不做 SFT。

```
A conversation ... The assistant first thinks
about the reasoning process and then provides
the answer. <think> ... </think>
<answer> ... </answer>
```

- **奖励 = 规则**：答案正确性 + 格式（用 `<think>` 标签）。**不用 PRM / 神经奖励模型**，避免被钻空子。
- **GRPO**：同题采 G 个，$\hat{A}_i = \dfrac{r_i - \text{mean}(r)}{\text{std}(r)}$，去掉价值网络（critic）。
- AIME 2024：15.6% → **71.0%**（投票 86.7%）；回答越来越长，出现“**aha moment**”式自我反思。
- **R1 流程**：冷启动 SFT（少量长思维数据）→ 推理 RL（加语言一致性奖励）→ 拒绝采样约 80 万条 SFT → 全场景 RL。AIME 79.8%，MATH-500 97.3%。
- 蒸馏：R1-Distill-Qwen-7B AIME 55.5%。

Kimi k1.5 Moonshot AI ·2501.12599 ·2025-01

RL 上下文 128k + partial rollouts；**不用 MCTS、价值函数、PRM**。AIME 77.5%，MATH500 96.2%。**long2short**：把长思维蒸到短回答（AIME 60.8%）。

要点：*test-time scaling* 从外部算法变成模型自身能力：结果奖励 + *RL* 就能让模型自己学会“多想、回头检查”。

8. 控制思考长度（2024-12 → 2025）

Overthinking: 2+3=? 腾讯 AI Lab / 上海交大·2412.21187 · 2024-12

“2+3”这种题，类 o1 模型比普通模型多用 **1,953%** 的 token。用偏好优化选更短的正确解，QwQ-32B 在 MATH500 上 token 减少约 48.6%，准确率基本不变。

Underthinking 腾讯 AI Lab ·2501.18585 ·2025-01

答错时 token 多 225%、换思路频率高 418%。**TIP** 解码：在一段思路内惩罚“换思路”类 token。QwQ AIME24 41.7 → 45.8。

s1: Simple Test-Time Scaling Stanford ·2501.19393 · 2025-01

- **s1K**：从 59K 题中按难度、多样性、质量选 1,000 题；微调 Qwen2.5-32B-Instruct，16 张 H100 训练 26 分钟。
- **Budget forcing**：

```
if 思考 token < 最小预算 and 模型想结束思考:
    抑制结束标记，追加 "Wait"   # 继续想
if 思考 token ≥ 最大预算:
    强行追加 "Final Answer:"   # 截断
```

AIME24 50.0% → 56.7%；竞赛数学最多比 o1-preview 高 27%。

L1 / LCPO CMU ·2503.04697 ·2025-03

提示里写“Think for n_{gold} tokens”，RL 奖励：

$$r = \mathbf{1}[y = y^*] - \alpha\,|n_{\text{gold}} - n_y|$$

L1-Exact（精确长度）/ L1-Max（上限）；同等长度下 1.5B 胜过 GPT-4o。

产品	控制方式
Claude 3.7（2025-02）	思考 token 预算，最高 128K
Gemini 2.5 Flash（2025-04）	预算 0–24,576，可关闭
Qwen3（2025-05）	思考 / 不思考两种模式 + 预算
gpt-oss（2025-08）	low / medium / high
GPT-5（2025-08）	路由器选快模型或 thinking
GPT-5.1 / Opus 4.6	**自适应思考**（模型自己决定）
GPT-5.2 / Opus 4.7	新增 xhigh 档

9. 在潜空间里思考（2024–2025）

Coconut Meta FAIR ·2412.06769 ·2024-12

最后一层隐藏状态 h_t 直接作为下一步的输入嵌入（“连续思维”），不解码成 token；一个连续思维可同时编码多条候选路径（类 BFS）。课程式训练：逐步把 CoT 的语言步骤换成连续思维。ProsQA 97.0% vs CoT 77.5%；GSM8K 34.1% vs CoT 42.9%（GPT-2）。

Recurrent Depth ELLIS / 马普所·2502.05171 ·2025-02

结构：prelude（编码）→ **循环核心块**（迭代 r 次）→ coda（解码）。训练时 r 随机，均值 32；3.5B 参数、800B token。推理时增加 r，算力最多相当于 50B 参数模型。

局限

思考过程不可读 → 难以监控；在数学文字题上还不如显式 CoT。

10. 测试时训练：推理时更新参数

Test-Time Training (TTT) UC Berkeley ·1909.13231 · 2019-09

Y 形网络：共享编码器 θ_e + 主任务头 θ_m + 自监督头 θ_s（预测旋转 0/90/180/270°）。测试时对每个样本：

$$\theta_e \leftarrow \theta_e - \eta \nabla_{\theta_e} \ell_s(x; \theta_e, \theta_s)$$

再用更新后的 θ_e 预测。

TENT UC Berkeley ·2006.10726 ·2020-06

最小化预测熵 $H(\hat{y}) = -\sum_c p(c)\log p(c)$，只更新 BatchNorm 的统计量和仿射参数 γ, β。ImageNet-C 错误率 59.5% → 44.0%。

TTT Layers Stanford ·2407.04620 ·2024-07

把 RNN 的隐藏状态做成一个模型 $f(\cdot; W)$，每个 token 做一步梯度下降：

$$W_t = W_{t-1} - \eta \nabla \ell(W_{t-1}; x_t)$$
$$\ell(W; x_t) = \|f(\theta_K x_t; W) - \theta_V x_t\|^2$$

输出 $z_t = f(\theta_Q x_t; W_t)$。TTT-Linear / TTT-MLP；超过 16k 上下文仍持续降低困惑度。

Titans Google ·2501.00663 ·2024-12

长期记忆 $\mathcal{M}$ 推理时学习，“惊讶度” = 关联记忆损失的梯度：

$$S_t = \eta_t S_{t-1} - \theta_t \nabla \ell(\mathcal{M}_{t-1}; x_t)$$
$$\mathcal{M}_t = (1-\alpha_t)\mathcal{M}_{t-1} + S_t$$

（动量 + 遗忘门）。上下文可超过 200 万 token。

TTT for ARC MIT ·2411.07279 ·2024-11

1. 用该题的 K 个示例做**留一法**构造训练任务 + 可逆几何变换增强；
2. 训练该题专属的 **LoRA**（rank 128）；
3. 对各种变换下的预测做分层投票。

8B 模型 ARC 公开验证集 **53%**，最多比微调基线高 6×；与程序合成集成 **61.9%**，与人类平均水平相当。

TTRL 清华·2504.16084 ·2025-04

```
对每道无标签测试题 x:
  采样 N 个解 → 多数投票得伪标签 â
  r_i = 1[ans(y_i) = â]        # 0/1 奖励
  用 GRPO 更新模型
```

Qwen2.5-Math-7B AIME 2024 pass@1 提升约 **211%**；训练后单次准确率超过训练前的多数投票。依赖初始模型多数投票有一定准确率。

11. 2025–2026 前沿

11a. 并行思考：从投票到训练出来的分叉与合并

工作	机制·数字
S^3 (2502.01839)	随机采样 + 自我验证；样本越多验证越准（隐式 scaling）
Self-Certainty (2502.18581)	用模型自身置信度挑样本，无需奖励模型
APR (2504.15466)	学会 `spawn()` / `join()` 子线程；Countdown 83.4% vs 60.0%
Claude 4 (2025-05)	并行补丁 + 测试过滤 + 打分：SWE-bench 72.5% → 79.4%
Deep Think (2025-07)	并行探索并合并多种解法；IMO 35/42 金牌
DeepConf (2508.15260)	按置信度过滤推理链；AIME25 最高 99.9%，token 最多 −84.7%
ParaThinker (2509.04475)	原生并行 8 路：1.5B +12.3%，延迟 +7.1%
DeepSeekMath-V2 (2511.22570)	验证器当奖励 + 扩大验证算力；Putnam 2024 118/120
Gemini 3 Deep Think	ARC-AGI-2 45.1%（2025-12）→ 84.6%（2026-02）
PaCoRe (2601.05593)	多轮并行、压缩成消息传给下一轮；8B HMMT25 94.5%

11b. 高效推理

NoThinking (`2504.09858`): 跳过思考 + 并行 best-of-N，700 token 下 51.3 vs 28.9 ·DEER (`2504.15895`): 换思路处试答、置信够高就停，链长 −19.1%∼−80.1% ·AdaptThink (`2505.13417`): RL 选择想或不想，长度 −53%、准确率 +2.4% ·short-m@k (`2505.17813`): 并行 k 条，最先结束的 m 条投票，比最长链准最多 34.5%。

11c. 验证器也 scaling

DeepSeek-GRM (`2504.02495`): 生成式 RM 先写原则和点评,推理时并行采样 + meta-RM 投票·ThinkPRM (`2504.16828`): 长思维逐步验证，只用 PRM800K 1% 标签·J1 (`2505.10320`): RL 训练会思考的评委。

11d. 测试时训练 / 推理时学习

AlphaEvolve (2025-05)	冻结的 Gemini 提代码 + 自动评测，进化迭代；4×4 复矩阵乘法 48 次乘法
Intuitor (2505.19590)	自身置信度当唯一奖励，无标签
SEAL (2506.10943)	模型写“自我编辑”数据并 SFT 自己
TRM (2510.04871)	7M 参数、2 层网络递归；ARC-AGI-1 45%
ARC Prize 2025	主题“精炼循环”：针对任务的训练都发生在测试时
TTT-E2E (2512.23675)	推理时对上下文继续做下一 token 训练；128K 时比全注意力快 2.7×
TTT-Discover (2601.16175)	针对单个问题做 RL；GPU kernel 快最多 2×

11e. Agent 的 test-time scaling

BrowseComp：表现随推理算力平滑上升，best-of-N 再 +15–25% ·TTI (`2506.07976`)：扩展**交互步数**而不是思考 token ·Kimi K2 Thinking：连续 200–300 次工具调用，BrowseComp 60.2% ·Recursive LMs (`2512.24601`)：长输入当变量，模型写代码递归调用自己。

12. 局限与争议

工作	结论
CoT 忠实性 (Anthropic, 2025-04)	模型用了提示却很少承认：Claude 3.7 Sonnet 25%，R1 39%
RL 扩展能力了吗? (2504.13837)	k 很大时基座 pass@k 更高 → RL 主要提升采样效率
ProRL (2505.24864)	反方：足够长、稳定的 RL 在各种 k 下都超过基座
Spurious Rewards (2506.10947)	随机奖励也让 Qwen2.5-Math-7B 在 MATH-500 +21.4（真实奖励 +29.1），Llama / OLMo 不行
Illusion of Thinking (2506.06941)	超过某复杂度准确率崩溃；思考 token 先增后减
反驳 (2506.09250)	失败多因输出长度上限、部分题无解；改为输出生成函数即恢复
Inverse Scaling (2507.14417)	有干扰项 / 虚假特征时，推理越长越差
CoT 可监控性 (2507.11473)	多家实验室立场文章：别破坏思维链的可监控性

13. 实践清单

从论文里总结的经验

1. **先画 pass@k 曲线**：覆盖率不涨，再好的挑选方法也没用（Monkeys）。
2. **有可靠验证器**（单元测试、证明检查）→ best-of-N / 搜索；**没有** → 投票、置信度、生成式验证。
3. **按难度分配算力**：简单题少想或不想，难题并行 + 串行（Snell、AdaptThink）。
4. **比较时按 FLOPs 或 token 对齐**，别只报最大 N 的结果。
5. **警惕验证器被过度优化**：N 越大越容易挑到“骗过验证器”的解（Cobbe、PRM）。
6. **长不等于对**：检查 inverse scaling 和过度思考；短链往往更准（short-m@k）。
7. **分布外、有结构的任务考虑 TTT**：ARC、单题优化（TTT-ARC、TTT-Discover）。

14. 推理模型训练配方对比

方法	数据·算法·奖励·关键技巧
R1-Zero	基座直接 RL；GRPO；规则奖励（正确性 + 格式）；无 SFT
R1	冷启动 SFT → 推理 RL（+ 语言一致性）→ 拒绝采样约 80 万条 SFT → 全场景 RL
Kimi k1.5	128k 上下文 RL + partial rollouts；不用 MCTS / 价值函数 / PRM；long2short
s1	只做 SFT：1,000 条精选长思维数据；推理时 budget forcing
L1	RL 奖励 = 正确性 − α | 目标长度 − 实际长度 |
AdaptThink	RL 学会每题选“想 / 不想”，约束优化保准确率
TTRL	测试集上 RL，奖励 = 与多数投票一致
Intuitor	奖励 = 模型自身置信度，无任何标签

15. 常见误区

容易说错的几句话

- **“采样越多越好”**：覆盖率会涨，但投票和验证器会饱和，难题上投票甚至变差。
- **“小模型 + 推理算力能替代大模型”**：只在小模型本来有一定成功率的题上成立。
- **“思维链 = 模型真实的思考过程”**：忠实性研究显示模型常常不说出真正用到的线索。
- **“o1 / R1 就是在推理时做 MCTS”**：两者都是 RL 训练出的单条长思维链；R1 和 k1.5 明确不用 MCTS / PRM。
- **“RL 让模型学会了新能力”**：仍有争议，大 k 下的 pass@k 对比是关键证据。
- **“TTT 就是微调”**：TTT 在每个测试样本上、用无标签信号临时更新，用完可丢弃。

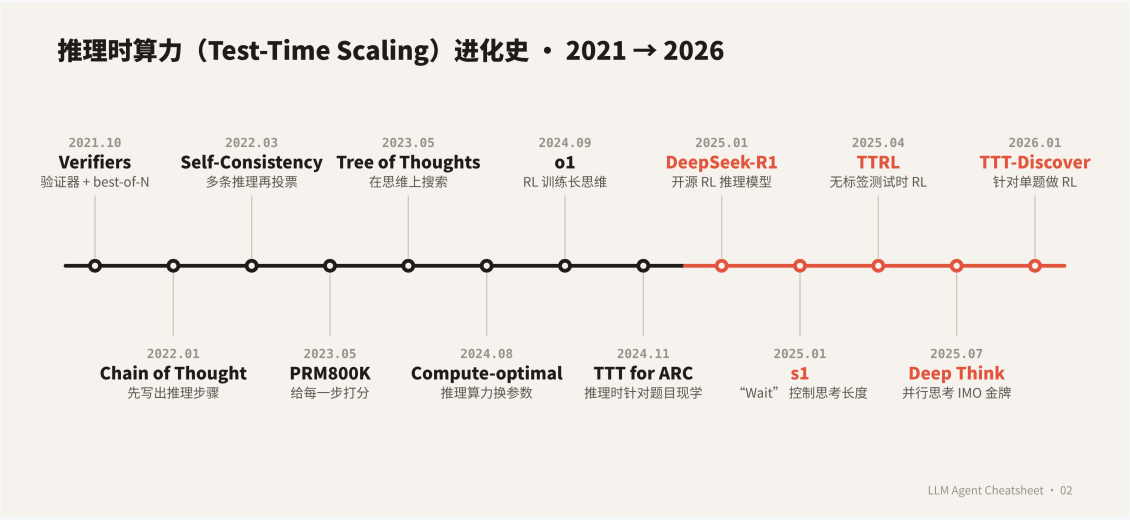
16. 常用评测基准

基准	规模·特点
GSM8K	8.5K 道小学数学（1K 测试）；已基本饱和
MATH / MATH-500	12.5K 道竞赛数学；MATH-500 是 Let's Verify 用的 500 题子集
AIME 24 / 25	每年 30 题，整数答案；推理模型的主战场，题少、方差大，常报多次平均（avg@k）
HMMT	哈佛-MIT 数学竞赛题，常与 AIME 一起报
GPQA Diamond	198 道研究生水平科学题，“谷歌搜不到答案”
LiveCodeBench	持续更新的竞赛编程题，按发布时间切分以防数据污染
SWE-bench Verified	500 个人工确认过的真实 GitHub 修 bug 任务
ARC-AGI-1 / 2	少样本网格推理谜题；测试时训练的主要试验场
HLE	Humanity's Last Exam，约 2,500 道前沿学科难题
BrowseComp	1,266 道难找、易验证的浏览题；看 agent 的推理算力曲线

读数字时注意

pass@1 / avg@k（单次平均）≠ **cons@k / maj@k**（k 次投票）≠ **pass@k**（k 次至少一次对，需要 oracle）。同一个模型三种报法可以差 10–20 个点；比较时还要看思考预算、是否用工具。

全景：13 个里程碑（黑 = 2021–2024，红 = 2025–2026）



速查：我的场景该用哪种?

答案能精确比对、没验证器 → 自一致性；开放式输出用 USC
有可执行测试 / 证明检查 → 大量采样 + 过滤（AlphaCode、Monkeys）
多步推理、能给步骤打分 → PRM + beam search；没人工标签用 Math-Shepherd / PAV
预算有限、难度不一 → compute-optimal 分配（Snell）、自适应思考
要训练推理模型 → 规则奖励 + GRPO（R1），控制长度用 L1 / s1
分布外、每题有示例 → 测试时训练（TTT-ARC）；无标签用 TTRL

笔者整理的方法路由，不是性能排名。

入门必读 6 篇（按顺序）

1 **Self-Consistency** 2203.11171 最简单的并行 scaling
2 **Let's Verify** 2305.20050 过程奖励 vs 结果奖励
3 **Snell et al.** 2408.03314 推理算力怎么换参数
4 **DeepSeek-R1** 2501.12948 只用 RL 训练长思维
5 **s1** 2501.19393 1,000 条数据 + “Wait”
6 **TTT for ARC** 2411.07279 推理时现学

综述: What, How, Where, and How Well? (2503.24235)·From System 1 to System 2 (2502.17419)·Stop Overthinking (2503.16419)·Trust but Verify (2508.16665)

自测：看完应该能回答（16 问）

Q1 自一致性和 best-of-N 的区别?
前者不需要验证器、只对最终答案投票；后者用验证器打分挑最高的。

Q2 为什么投票会饱和，甚至越投越差?
难题上错误答案可能占多数，样本越多越稳定地选中它。

Q3 覆盖率（pass@k）和实际准确率差在哪?
覆盖率假设有 oracle 知道哪个对；实际要靠投票或验证器挑，常在几百个样本后饱和。

Q4 PRM 怎么给整条解打分?
各步正确概率相乘（Let's Verify），也有取最小值的做法。

Q5 Math-Shepherd 怎么不用人工标步骤?
从该步往后续写 8 次，看能否到达正确答案（hard / soft 两种标签）。

Q6 “compute-optimal” 指什么?
按题目难度选推理策略，比 best-of-N 省 4× 以上；小模型 + 推理算力只在中等难度题上胜过大模型。

Q7 推理 FLOPs 和训练 FLOPs 怎么比?
预训练约 $6ND_{\text{pre}}$，推理约 $2ND_{\text{inf}}$；推理次数多时，大模型的推理成本也很高。

Q8 R1-Zero 为什么不用 PRM?
神经奖励模型在大规模 RL 中容易被钻空子；规则奖励（答案对错 + 格式）更稳。

Q9 GRPO 和 PPO 的主要区别?
用组内归一化的奖励当优势，去掉了价值网络。

Q10 s1 的 budget forcing 怎么做?
想停时抑制结束标记、追加“Wait”；到上限就强制给出答案。

Q11 过度思考和思考不足分别指什么?
简单题写太多 token；难题频繁换思路、每条都没想完。

Q12 潜空间推理的代价?
思考过程不可读、难以监控；数学文字题上还不如显式 CoT。

Q13 TTT 和上下文学习（ICL）的区别?
TTT 更新权重，ICL 只用上下文；TTT 层把隐藏状态做成权重，统一了两者。

Q14 TTRL 的奖励从哪来? 风险是?
多数投票的伪标签；如果初始多数投票就错，会强化错误答案。

Q15 “RL 没有扩展能力边界”的证据和反方?
大 k 时基座 pass@k 更高（2504.13837）；ProRL 认为足够长的 RL 能扩展。

Q16 “想得越久越差”的例子?
带干扰项的任务（Inverse Scaling）；高复杂度谜题的准确率崩溃（Illusion of Thinking，有争议）。

关键数字速记

Jones 2021	训练 10× ≈ 推理 15×
GSM8K 验证器	6B + 验证器 ≈ 30× 模型
CoT	PaLM GSM8K 17.9 → 56.9
Self-Consistency	GSM8K +17.9（40 条）
PRM800K	PRM 78.2 / ORM 72.4 / 投票 69.6
ToT	24 点 4% → 74%
Monkeys	SWE-bench Lite 15.9 → 56%
Snell	>4× 效率；胜 14× 大模型
o1	AIME 74 / 83 / 93%
R1-Zero	AIME 15.6 → 71.0（投票 86.7）
s1	1K 数据；AIME 50.0 → 56.7
过度思考	2+3 多用 1,953% token
TTT-ARC	53%；集成 61.9%
TTRL	AIME pass@1 约 +211%
Claude 4 并行	SWE-bench 72.5 → 79.4
Deep Think	IMO 2025 35/42
DeepConf	token 最多 −84.7%
Gemini 3 DT	ARC-AGI-2 84.6%（2026-02）
Spurious Rewards	随机奖励 +21.4

日期为首次公开月份（arXiv v1 或官方发布）；机构为第一作者主要单位；数字取自原文主结果，不同设置下可能不同。完整中英双语版与全部链接：GitHub EvenEureka/llm-agent-cheatsheet。发现错误欢迎指出。